n [2]: ut[2]:	<pre>import seaborn as sns import scipy.stats as stats import os import warnings warnings.filterwarnings("ignore")  import statsmodels.api as sm from statsmodels.stats.anova import anova_lm import scipy.stats as stats import matplotlib.pyplot as plt from sklearn.preprocessing import StandardScaler, PowerTransformer, LabelEncoder, OneHotEncoder, MinMaxScal pd.set_option('display.max_columns', None) pd.set_option('display.max_rows', None)</pre>
	<pre>df2 = pd.read_csv('Csv_files/out.csv') df2.head()</pre>
n [3]:	1 Caucasian Female 75 Emergency Discharged/transferred to another rehab fac in Emergency Room 7 MC  2 Caucasian Female 95 Emergency Discharged to home Emergency Room 4 MC E  3 Caucasian Male 75 Emergency Discharged/transferred to another short term h Emergency Room 10 MC  4 Caucasian Male 55 Emergency Left AMA Transfer from another health care facility 6 MC
nt[3]:	Index(['RACE', 'GENDER', 'AGE_INT', 'ADMISSION_TYPE', 'DISCHARGE_DISPOSITION',
n [4]: nt[4]:	Exploration et nettoyage des données pour appliquer les modèles de machine learning  On va effectuer des tâches supplémentaire de nettoyage des données telles que la suppression de mauvaises données, le traitement des valeurs manquantes
[5]:	<pre>df2.info()  <class 'pandas.core.frame.dataframe'=""> RangeIndex: 26755 entries, 0 to 26754 Data columns (total 47 columns): RACE</class></pre>
	PAYER_CODE       26755 non-null object         MEDICAL_SPECIALTY       26755 non-null int64         NUM_LAB_PROCEDURES       26755 non-null int64         NUM_PROCEDURES       26755 non-null int64         NUM_MEDICATIONS       26755 non-null int64         NUMBER_OUTPATIENT       26755 non-null int64         NUMBER_EMERGENCY       26755 non-null int64         NUMBER_INPATIENT       26755 non-null object         DIAG_1       26755 non-null object         DIAG_2       26755 non-null object         DIAG_3       26755 non-null int64         NUMBER_DIAGNOSES       26755 non-null object         NUMBER_DIAGNOSES       26755 non-null object         A1CRESULT       26755 non-null object
	METFORMIN26755non-nullobjectREPAGLINIDE26755non-nullobjectNATEGLINIDE26755non-nullobjectCHLORPROPAMIDE26755non-nullobjectGLIMEPIRIDE26755non-nullobjectACETOHEXAMIDE26755non-nullobjectGLIPIZIDE26755non-nullobjectGLYBURIDE26755non-nullobjectTOLBUTAMIDE26755non-nullobjectPIOGLITAZONE26755non-nullobjectROSIGLITAZONE26755non-nullobjectACARBOSE26755non-nullobjectMIGLITOL26755non-nullobject
	TROGLITAZONE 26755 non-null object  TOLAZAMIDE 26755 non-null object  EXAMIDE 26755 non-null object  CITOGLIPTON 26755 non-null object  INSULIN 26755 non-null object  GLYBURIDE_METFORMIN 26755 non-null object  GLIPIZIDE_METFORMIN 26755 non-null object  GLIPIZIDE_METFORMIN 26755 non-null object  GLIMEPIRIDE_PIOGLITAZONE 26755 non-null object  METFORMIN_ROSIGLITAZONE 26755 non-null object  METFORMIN_PIOGLITAZONE 26755 non-null object  CHANGE 26755 non-null object  DIABETESMED 26755 non-null object  READMITTED 26755 non-null object
n [6]:	diz.describe()
	count         26755.000000         26755.000000         26755.000000         26755.000000         26755.000000           mean         66.608671         4.317922         40.756681         1.475575         16.246720         0.290712           std         15.582391         2.949791         19.965546         1.749729         8.609362         0.998707           min         5.000000         1.000000         0.000000         1.000000         0.000000         0.000000           25%         55.000000         2.000000         29.000000         0.000000         10.000000         0.000000           50%         65.000000         4.000000         42.000000         1.000000         20.000000         0.000000           75%         75.000000         6.000000         54.000000         2.000000         20.000000         0.000000
	<pre>max 95.000000 14.000000 132.000000 6.000000 81.000000 38.000000  'RACE', 'GENDER', 'AGE_INT', 'ADMISSION_TYPE', 'DISCHARGE_DISPOSITION', 'ADMISSION_SOURCE', 'TIME_IN_HOSPITAL', 'PAYER_CODE', 'MEDICAL_SPECIALTY', 'NUM_LAB_PROCEDURES', 'NUM_PROCEDURES', 'NUM_MEDICATIONS', 'NUMBER_OUTPATIENT', 'NUMBER_EMERGENCY', 'NUMBER_INPATIENT', 'DIAG_1', 'DIAG_2', 'DIAG_3', 'NUMBER_DIAGNOSES', 'MAX_GLU_SERUM', 'A1CRESULT', 'METFORMIN', 'REPAGLINIDE', 'NATEGLINIDE', 'CHLORPROPAMIDE', 'GLIMEPIRIDE', 'ACETOHEXAMIDE', 'GLIPIZIDE', 'GLYBURIDE', 'TOLBUTAMIDE', 'PIOGLITAZONE', 'ROSIGLITAZONE', 'ACARBOSE',</pre>
[7]:	'MIGLITOL', 'TROGLITAZONE', 'TOLAZAMIDE', 'EXAMIDE', 'CITOGLIPTON',  'INSULIN', 'GLYBURIDE_METFORMIN', 'GLIPIZIDE_METFORMIN',  'GLIMEPIRIDE_PIOGLITAZONE', 'METFORMIN_ROSIGLITAZONE',  'METFORMIN_PIOGLITAZONE', 'CHANGE', 'DIABETESMED', 'READMITTED'  Nous avons 47 variables, alors jetons un coup d'œil à chacun.  1. RACE: C'est une variable catégorielle.  print(df2['RACE'].value_counts())  df2['RACE'].value_counts().plot(kind='pie',autopct='%.2f%%',figsize=(15,5))  plt.show()
	Caucasian 20183 AfricanAmerican 5359 Hispanic 487 Other 476 Asian 250 Name: RACE, dtype: int64  Caucasian
	Asian Other Hispanic 20.03%  AfricanAmerican  Il y a 5 catégories distinctes pour la variable RACE.
[8]: [9]: [9]:	Pour le remplissage des valeurs nulles, nous avons essayé de remplacer par mode, en effectuant une substitution selon la distribution prob, en supprimant les valeurs nulles mais en supprimant les valeurs nulles semblant obtenir les meilleurs résultats.  df2 = df2.dropna()  df2.shape
[10]:	2. GENDER: C'est une caractéristique catégorique représentant le sexe du patient.  sns.countplot(df2.GENDER) plt.show() print(df2.GENDER.value_counts())
	# 8000 - 6000 - 4000 - 2000 - Female GENDER Male  Female 14101
[11]: [12]:	df2['GENDER'] = df2['GENDER'].replace({'Female' : 0, 'Male' : 1})  3. AGE_INT: C'est l'age du personne; on a déja traiter ces valeurs avec SQL
	df2.groupby('AGE_INT').size().plot(kind='bar') plt.ylabel('Count') plt.show()  6000- 5000- 4000- 3000-
	L'âge ici varie de 0 à 100 ans.  La population comprise entre 50 et 90 ans est principalement présente dans cet ensemble de données.
[13]: [13]:	diz.ADMISSION_IPE.Nunique()
[14]: [15]:	diz[ ADMISSION_TIPE ]-diz[ ADMISSION_TIPE ].Teptace({
	12500 - 10000
[16]: [16]:	diz[diz['ADMISSION_TIPE']== 'Newborn'][['GENDER', 'AGE_INT', 'ADMISSION_TIPE']]
[17]: [18]: [18]:	df2.ADMISSION_TYPE.value_counts()  Emergency 17874 Elective 8014 Not Available 37 Name: ADMISSION_TYPE, dtype: int64
[19]: [19]:	Discharged to home  16621  Discharged/transferred to SNF  4047  Discharged/transferred to home with home health service  2527  Discharged/transferred to another rehab fac including rehab units of a hospital .
	Discharged/transferred to another short term hospital 593 Expired 426 Discharged/transferred to another type of inpatient care institution 225 Discharged/transferred to ICF 222 Left AMA 155 Discharged/transferred to a long term care hospital. 139
	Hospice / home 115 Hospice / medical facility 38 Discharged/transferred/referred to a psychiatric hospital of psychiatric distinct part unit of a hospital 11 Expired at home. Medicaid only, hospice. 8 Discharged/transferred to home under care of Home IV provider 6 Discharged/transferred to a nursing facility certified under Medicaid but not certified under Medicare. 5 Discharged/transferred within this institution to Medicare approved swing bed
	Not Mapped  1 Admitted as an inpatient to this hospital  1 Discharged/transferred to a federal health care facility.  1 Name: DISCHARGE_DISPOSITION, dtype: int64  discharge_disposition_id description  1 Discharged to home
	2 Discharged/transferred to another short term hospital  3 Discharged/transferred to SNF(skilled nursing facility)  4 Discharged/transferred to ICF(intermediate care facility)  5 Discharged/transferred to another type of inpatient care institution  6 Discharged/transferred to home with home health service  7 Left AMA(Against Medical Advice.)
	8 Discharged/transferred to home under care of Home IV provider  9 Admitted as an inpatient to this hospital  10 Neonate discharged to another hospital for neonatal aftercare  11 Expired  12 Still patient or expected to return for outpatient services  13 Hospice / home
	14 Hospice / medical facility  15 Discharged/transferred within this institution to Medicare approved swing bed  16 Discharged/transferred/referred another institution for outpatient services  17 Discharged/transferred/referred to this institution for outpatient services  18 NULL
	19 Expired at home. Medicaid only, hospice. 20 Expired in a medical facility. Medicaid only, hospice. 21 Expired, place unknown. Medicaid only, hospice. 22 Discharged/transferred to another rehab fac including rehab units of a hospital. 23 Discharged/transferred to a long term care hospital. 24 Discharged/transferred to a nursing facility certified under Medicaid but not certified under Medicare.
	25 Not Mapped  26 Unknown/Invalid  30 Discharged/transferred to another Type of Health Care Institution not Defined Elsewhere  27 Discharged/transferred to a federal health care facility.  28 Discharged/transferred/referred to a psychiatric hospital of psychiatric distinct part unit of a hospital
	29 Discharged/transferred to a Critical Access Hospital (CAH).  Nous pouvons fusionner plusieurs groupes ici pour réduire le nombre de catégories:  1> Discharged to home  2/3/4/5/10/16/22/23/24/30/27/28/29> Transferred to another medical facility  7> Left AMA(Against Medical Advice.)  6/8> Discharged to home with home health service
[20]:	9/12/15/17> Still patient/referred to this institution  11/19/20/21> Expired  18/25/26> Not Available  13/14> Hospice  df2['DISCHARGE_DISPOSITION']=df2['DISCHARGE_DISPOSITION'].replace({'Discharged to home':'Discharged to home':'Discharged to another short term hospital':'Transferred to another medical factorizations.
	'Discharged/transferred to ICF':'Transferred to another medical far 'Discharged/transferred to another type of inpatient care institut.'  'Discharged/transferred to another rehab fac including rehab units  'Discharged/transferred to a long term care hospital.':'Transferred  'Discharged/transferred to a nursing facility certified under Medicare description of the provider of the
[21]: [21]:	Discharged to home 16621 Transferred to another medical facility 6024 Discharged/transferred to home with home health service 2527 Expired 434 Left AMA 155
[22]:	df2=df2[df2['DISCHARGE_DISPOSITION']!='Expired'] df2=df2[df2['DISCHARGE_DISPOSITION']!='Hospice']  6. ADMISSION_SOURCE: Identifiant entier correspondant à 17 valeurs distinctes, par exemple,
[23]: [23]:	recommandation d'un médecin, salle d'urgence et transfert d'un hôpital  df2.ADMISSION_SOURCE.value_counts(sort=False)
	Clinic Referral 47 Sick Baby 1 Court/Law Enforcement 5 HMO Referral 10 Name: ADMISSION_SOURCE, dtype: int64  1 Physician Referral 2 Clinic Referral 3 HMO Referral 4 ADMISSION_SOURCE 4 ADMISSION_SOURCE 5 ADMISSION_SOURCE 6 ADMISSION_SOURCE 6 ADMISSION_SOURCE 7 ADMISSION_SOURCE 7 ADMISSION_SOURCE 7 ADMISSION_SOURCE 8
	4 Transfer from a hospital  5 Transfer from a Skilled Nursing Facility (SNF)  6 Transfer from another health care facility  7 Emergency Room  8 Court/Law Enforcement  9 Not Available
	10 Transfer from critial access hospital  11 Normal Delivery  12 Premature Delivery  13 Sick Baby  14 Extramural Birth  15 Not Available
	17 NULL  18 Transfer From Another Home Health Agency  19 Readmission to Same Home Health Agency  20 Not Mapped  21 Unknown/Invalid
	22 Transfer from hospital inpt/same fac reslt in a sep claim 23 Born inside this hospital 24 Born outside this hospital 25 Transfer from Ambulatory Surgery Center 26 Transfer from Hospice  Nous pouvons fusionner plusieurs groupes ici pour réduire le nombre de catégories:
	1/2/3> Referral  4/5/6/10/18/19/25/26/22> Transferred from another health care facility  7> Emergency  9/15/17/20/21> Not Available  8> Court/Law Enforcement
[24] <b>:</b>	Delivery> 11/12/14/13/23/24  df2['ADMISSION_SOURCE']=df2['ADMISSION_SOURCE'].replace({'Physician Referral':'Referral',
[25]: [25]:	diz.ADMISSION_SOURCE.Value_Counts()
[26]:	<pre>Name: ADMISSION_SOURCE, dtype: int64  df2[df2['ADMISSION_SOURCE']=='Delivery'][['GENDER','AGE_INT','ADMISSION_SOURCE']]</pre>
[27]:	df2=df2[df2[LADMIGGION CONT.]
[28]: [29]:	<ul> <li>Puisque nous avons 2 colonnes concernant l'admission, type_id et source_id, nous avons utilisé ces informations pour remplir les valeurs "Not Available" dans les colonnes admission_source_id par rapport à admission_type_id. Par exemple, si admission_type_id est Emergency mais admission_source_id n'est pas disponible, nous pouvons remplir Emergency (mode) à cet endroit.</li> <li>Après l'avoir remplie, la colonne admission_type_id a été supprimée car elle donnait les mêmes informations que admission_source_id et était moins significative statistiquement.</li> </ul>
	Puisque nous avons 2 colonnes concernant l'admission, type_id et source_id, nous avons utilisé ces informations pour remplir les valeurs "Not Available" dans les colonnes admission_source_id par rapport à admission_type_id. Par exemple, si admission_type_id est Emergency mais admission_source_id n'est pas disponible, nous pouvons remplir Emergency (mode) à cet endroit.  Après l'avoir remplie, la colonne admission_type_id a été supprimée car elle donnait les mêmes informations que admission_source_id et était moins significative statistiquement.  df2 = df2.reset_index(drop = True)  # Avant df2[df2['ADMISSION_TYPE'] == 'Emergency'] ['ADMISSION_SOURCE'].value_counts()  Emergency 12395 Referral 2793 Transferred from another health care facility 2160 Not Available 39 Name: ADMISSION_SOURCE, dtype: int64
[30]: [31]:	Puisque nous avons 2 colonnes concernant l'admission, type_id et source_id, nous avons utilisé ces informations pour remplir les valeurs "Not Available" dans les colonnes admission_source_id par rapport à admission_type_id. Par exemple, si admission_type_id est Emergency mais admission_source_id n'est pas disponible, nous pouvons remplir Emergency (mode) à cet endroit.  Après l'avoir remplie, la colonne admission_type_id a été supprimée car elle donnait les mêmes informations que admission_source_id et était moins significative statistiquement.  df2 = df2.reset_index(drop = True )  # Avant df2[df2['ADMISSION_TYPE'] == 'Emergency'] ['ADMISSION_SOURCE'].value_counts()  Emergency
[30]: [31]: [32]:	<ul> <li>Puisque nous avons 2 colonnes concernant l'admission, type_id et source_id, nous avons utilisé ces informations pour remplir les valeurs "Not Available" dans les colonnes admission_source_id par rapport à admission_type_id. Par exemple, si admission_type_id est Emergency mais admission_type_id n'est pas disponible, nous pouvons remplir Emergency (mode) à cet endroit.</li> <li>Après l'avoir remplie, la colonne admission_type_id a été supprimée car elle donnaît les mêmes informations que admission_source_id et était moins significative statistiquement.</li> <li>df2 = df2_reaset_index(drop = True )</li> <li> # Avant dt2[df2['ADMISSION_TYPE']="Emergency']['ADMISSION_SOURCE'].value_counts()</li> <li> # Emergency</li></ul>
[30]: [31]: [32]: [33]:	<ul> <li>Puisque nous avons 2 colonnes concernant l'admission, type_id et source_id, nous avons utilisé ces informations pour remplir les valeurs "Not Available" dans les colonnes admission, source_id par rapport à admission, type_id a remple, si admission, type_id est Emergency mais admission source_id n'est pas disponible, nous pouvons remplir Emergency (mode) à cet endroit.</li> <li>Après l'avoir remplie, la colonne admission_type_id a été supprimée car elle donnait les mêmes informations que admission_source_id et était moins significative statistiquement.</li> <li>df2 = df2.reset_index(drop = True )</li> <li>8 Avant dt2[df2['ADMISSION_TYPE']=='Emergency']['ADMISSION_SOURCE'].value_counts()</li> <li>Emergency</li></ul>
[30]: [31]: [32]: [32]:	• Pulsage nous awons 2 colonnes concernant ladmission, type id et source id nous awons utiliad ces informations pour rempilir les valeurs 'Not Available' dans les colonnes admission source id par rapport à admission, type id et supprime car se property model a cet entroit.  • Apres lavoir rempile la colonne admission, type id a été supprime car elle donnait les memes informations que admission source id été aut mois signification statistiquement.  ctr = dr2.exext index(drop = True)  * Awons  # Awons  # Awons    Awons
[30]: [31]: [32]: [33]:	Pulsage nous avons 2 colonnes concernant fadmission, type_id et source_id, nous avons utilise ces informations pour remplir les userus. Not Available? dans les colonnes admission, source_id par capport à admission type_id. Par evemple, si admission source_id nous pouvons remplir fineregency (mode) a cet encrit.  - Après Newni comple, la colonne admission jusque, del se sportmet (ar elle dounnit les mêmes informations que admission source id et était mains significative statistiquement.  - Après Newni comple, la colonne admission jusque de del pour de la colonne de del admission source id et était mains significative statistiquement.  - Après Newni comple, la colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission source id et était mains significative statistiquement.  - Après Newni colonne de del admission de la colonne de la colo
[30]: [31]: [32]: [34]: [34]:	Pulsage now award colones concerned l'admission, type il et source id, now award with cres informations pure rempile to valeurs "Not Available" dans is colones admission, type id et source id par apport à admission, type id est frengency mais designed, course out on the part of the colones admission, type id est frengency mais designed, course the distinct is referred in the colone admission type id est designed in est part of the colones admission, course de étal mois againticter statisquement.  ### 2012
[30]: [31]: [32]: [33]: [34]:	* Pulsage note above? colones concerns l'admission spyre, il et source, il, nous avons utilise ces informations pour rempile le values. You Available i dans les coloness admission source id par apport à admission type id est mergany mais admission source id rest pas disposition, por id est est apportence or elle domait les mêmes informations que admission source d'el était noises significante statistiquement.  ### Command
[30]: [31]: [32]: [34]: [34]:	Pulsaus roots work colones processed administrative plant approach administrative por receptified and substitutions for scholones administrative por administrative por prompting devices the administrative por in our part of participated administrative production that administrative production that administrative production administrative production administrative production administrative production administrative production and administrative production and administrative production administrative production administrative production administrative production administrative production administrative productive p
[30]: [31]: [32]: [33]: [34]: [36]:	Processor Section Control
[30]: [31]: [32]: [33]: [34]: [34]: [38]: [38]:	Politics design above a convolution conservant information appeal of contents of the character and control without politics and cont
[32]: [32]: [33]:	Place of the control columns control foliation in parallel control from control foliations give treatly to other Mill Abrillation for the control from column Mill Abrillation for the control from column Mill Abrillation for the column Mill Abrillation of the column Mill Abrillation Column
[30]: [31]: [32]: [32]: [33]: [34]: [36]:	**Money that a body a coloring concentral and issues they are to built to builty. A real and will be incomed on a coloring of the second of th
[30]: [31]: [32]: [33]: [34]: [34]: [38]:	Principle of the control of the cont
[30]: [31]: [32]: [33]: [34]: [34]: [38]:	Productions across cluder to anternal histories integrated and extract by an integration of the state of the
[30]: [31]: [32]: [33]: [34]: [35]: [36]:	The content of the co
[30]: [31]: [32]: [33]: [34]: [34]: [38]:	Laboration and the control of the co

	<pre>ord('E'), ord('V')  (69, 86)  for i in diag_cols:     for j in range(len(df2[i])):         if str(df2.loc[j, i])[:3] == '250':</pre>
	<pre>df2.loc[j, i] = 'Diabetes' elif ord(str(df2.loc[j, i])[0]) in range(69, 87):     df2.loc[j, i] = 'External causes of injury' elif df2.loc[j, i] == '?':     df2.loc[j, i] = 'Missing' else:     x = float(df2.loc[j, i])     if x in range(390, 460) or x == 785:         df2.loc[j, i] = 'Circulatory'     elif x in range(460, 520) or x == 786:         df2.loc[j, i] = 'Respiratory' elif x in range(520, 580) or x == 787:         df2.loc[j, i] = 'Digestive'</pre>
	<pre>elif x in range(800, 1000):     df2.loc[j, i] = 'Injury and Poisoning' elif x in range(710, 740):     df2.loc[j, i] = 'Musculoskeletal System and Connective Tissue' elif x in range(580, 630) or x == 788:     df2.loc[j, i] = 'Genitourinary' elif x in range(140, 230):     df2.loc[j, i] = 'Neoplasms' elif x in [780, 781, 784] or x in range(790, 800):     df2.loc[j, i] = 'Other Symptoms' elif x in range(240, 280):     df2.loc[j, i] = 'Endocrine, Nutritional, Metabolic, Immunity' elif x in range(680, 710) or x == 782:     df2.loc[j, i] = 'Skin and Subcutaneous Tissue'</pre>
	<pre>elif x in range(1, 140):     df2.loc[j, i] = 'Infectious and Parasitic' elif x in range(290, 320):     df2.loc[j, i] = 'Mental Disorders' elif x in range(280, 290):     df2.loc[j, i] = 'Blood and Blood-Forming Organs' elif x in range(320, 360):     df2.loc[j, i] = 'Nervous' elif x in range(630, 680):     df2.loc[j, i] = 'Pregnancy, Childbirth' elif x in range(360, 390):     df2.loc[j, i] = 'Sense Organs'</pre>
[47]: [48]:	<pre>else:</pre>
[49]: t[49]:	<pre>if df2.loc[i, 'DIAG_2'] == 'Not Required' or df2.loc[i, 'DIAG_2'] != 'Missing':</pre>
	Circulatory       7623       8110       7647         Congenital Anomalies       210       146       110         Diabetes       2183       2918       4339         Digestive       2244       1090       951         Endocrine, Nutritional, Metabolic, Immunity       694       2120       2344         External causes of injury       243       660       1382         Genitourinary       1191       1804       1583         Infectious and Parasitic       557       472       433
	Injury and Poisoning 1801 610 488  Mental Disorders 539 662 776  Musculoskeletal System and Connective Tissue 1613 553 560  Neoplasms 825 646 441  Nervous 240 323 385  Other Symptoms 680 638 621  Pregnancy, Childbirth 229 149 97
[50]: :[50]:	Respiratory       3441       2634       1802         Sense Organs       60       40       60         Skin and Subcutaneous Tissue       682       1061       699         len(df2[df2['DIAG_1'] == 'Missing'])       "Missing'])
[51]: [51]:	19. NUMBER_DIAGNOSES: Nombre de diagnostics saisis dans le système  sns.countplot (df2.NUMBER_DIAGNOSES) <matplotlib.axessubplots.axessubplot 0x29f9ab34f48="" at="">  12000</matplotlib.axessubplots.axessubplot>
	Le nombre de diagnostics saisis dans le système va de 1 à 16.
[52]: :[52]:	20. MAX_GLU_SERUM: Indique la plage du résultat ou si le test n'a pas été effectué.  Valeurs: "> 200", "> 300", "normal" et "None" si non mesuré  df2.MAX_GLU_SERUM.value_counts()  None
[53]: [53]:	Mone 21217 >8 1914 Norm 1122 >7 1084 Name: AlCRESULT, dtype: int64  Valeurs: "> 8" si le résultat est supérieur à 8%  «> 7» si le résultat est supérieur à 7% mais inférieur à 8%
	«Normal» si le résultat est inférieur à 7%  «Aucun» s'il n'est pas mesuré.  22. caractéristiques pour les médicaments:  Pour les noms génériques: METFORMIN, REPAGLINIDE, NATEGLINIDE, CHLORPROPAMIDE, GLIMEPIRIDE, ACETOHEXAMIDE, GLIPIZIDE GLYBURIDE, TOLBUTAMIDE, PIOGLITAZONE, ROSIGLITAZONE, ACARBOSE, MIGLITOL, TROGLITAZONE, TOLAZAMIDE, EXAMIDE, CITOGLIPTON, INSULIN, GLYBURIDE_METFORMIN, GLIPIZIDE_METFORMIN, GLIMEPIRIDE_PIOGLITAZONE,  METFORMIN_ROSIGLITAZONE, et METFORMIN_PIOGLITAZONE
	La fonction indique si le médicament a été prescrit ou s'il y a eu un changement de posologie.  Valeurs: «up» si la posologie a été augmentée pendant la rencontre  «Down» si le dosage a été diminué  «Stable» si la posologie n'a pas changé  «Non» si le médicament n'a pas été prescrit  meds = ['METFORMIN', 'REPAGLINIDE', 'NATEGLINIDE', 'CHLORPROPAMIDE',
	'PIOGLITAZONE', 'ROSIGLITAZONE', 'ACARBOSE', 'MIGLITOL', 'TROGLITAZONE',     'TOLAZAMIDE', 'EXAMIDE', 'CITOGLIPTON', 'INSULIN',     'GLYBURIDE_METFORMIN', 'GLIPIZIDE_METFORMIN',     'GLIMEPIRIDE_PIOGLITAZONE', 'METFORMIN_ROSIGLITAZONE',     'METFORMIN_PIOGLITAZONE']  for i in meds:     print(i, df2[i].unique())  METFORMIN ['No' 'Steady' 'Up' 'Down'] REPAGLINIDE ['No' 'Steady' 'Up' 'Down'] NATEGLINIDE ['No' 'Steady' 'Down' 'Up']
	CHLORPROPAMIDE ['No' 'Steady'] GLIMEPIRIDE ['No' 'Steady' 'Up' 'Down'] ACETOHEXAMIDE ['No'] GLIPIZIDE ['No' 'Steady' 'Down' 'Up'] GLYBURIDE ['No' 'Steady' 'Up' 'Down'] TOLBUTAMIDE ['No'] PIOGLITAZONE ['No' 'Up' 'Steady' 'Down'] ROSIGLITAZONE ['No' 'Steady' 'Up' 'Down'] ACARBOSE ['No' 'Steady' 'Up' 'Down'] MIGLITOL ['No' 'Steady' 'Up' 'Down'] TROGLITAZONE ['No'] TOLAZAMIDE ['No'] EXAMIDE ['No'] CITOGLIPTON ['No']
[55]:	<pre>INSULIN ['Steady' 'No' 'Up' 'Down'] GLYBURIDE_METFORMIN ['No' 'Steady' 'Up' 'Down'] GLIPIZIDE_METFORMIN ['No' 'Steady'] GLIMEPIRIDE_PIOGLITAZONE ['No'] METFORMIN_ROSIGLITAZONE ['No'] METFORMIN_PIOGLITAZONE ['No' 'Steady']  Nous pouvons supprimer examide, citoglipton et metformin-rosiglitazone car ils ne sont pas prescrit à aucun patient.  df2.drop(['EXAMIDE', 'CITOGLIPTON', 'METFORMIN_ROSIGLITAZONE'], axis = 1, inplace = True)  meds = ['METFORMIN', 'REPAGLINIDE', 'NATEGLINIDE', 'CHLORPROPAMIDE',</pre>
[57] <b>:</b>	'GLIMEPIRIDE', 'ACETOHEXAMIDE', 'GLIPIZIDE', 'GLYBURIDE', 'TOLBUTAMIDE',     'PIOGLITAZONE', 'ROSIGLITAZONE', 'ACARBOSE', 'MIGLITOL', 'TROGLITAZONE',     'TOLAZAMIDE', 'INSULIN', 'GLYBURIDE_METFORMIN', 'GLIPIZIDE_METFORMIN',     'GLIMEPIRIDE_PIOGLITAZONE', 'METFORMIN_PIOGLITAZONE']  # Les médicaments peuvent être codés comme ci-dessous  for i in meds:     df2[i] = df2[i].replace({'No' : -2,
	<pre>for i in meds:     df2[i] = df2[i].astype('int64')  23. CHANGE: Indique s'il y a eu un changement dans les médicaments diabétiques (soit la posologie, soit le nom générique)  df2.CHANGE.value_counts()</pre>
[60]:	No 11514 Name: CHANGE, dtype: int64  df2['CHANGE'] = df2['CHANGE'].replace({'No' : 0, 'Ch' : 1})  24. DIABETESMED: Indique si un médicament diabétique a été prescrit.  df2.DIABETESMED.value_counts()  Yes 20790 No 4547
[62]: [63]:	No 4547 Name: DIABETESMED, dtype: int64  df2['DIABETESMED'] = df2['DIABETESMED'].replace({'Yes' : 1, 'No' : 0})  25. READMITTED: Outcome variable  Le résultat que nous examinons est de savoir si le patient est réadmis à l'hôpital dans les 30 jours ou non.  df2.READMITTED.value_counts()
	NO 14044 >30 8539 <30 2754 Name: READMITTED, dtype: int64  Le résultat a en fait des catégories <30,> 30 et Aucune réadmission. notre problème, nous allons le convertir en 2 catégories, c'est-à-dire pas de réadmission ou de réadmission dans 30 jours  df2['READMITTED'] = df2['READMITTED'].replace('>30', 'NO') df2['READMITTED'] = df2['READMITTED'].replace( {'NO': 0, '<30': 1} ).astype(int)  df2.reset_index(drop = True, inplace = True)
	(ADDITIONAL) Création de nouvelles fonctionnalités et suppression des fonctionnalités redondantes  1. Visites de l'année précédente:  'NUMBER_OUTPATIENT', 'NUMBER_EMERGENCY', 'NUMBER_INPATIENT' ont été combinés en les additionnant pour obtenir le nombre total de visites du patient au cours de l'année précédente, puis en supprimant les fonctionnalités de combinaison.  df2['preceding_year_visits']=df2['NUMBER_OUTPATIENT']+df2['NUMBER_EMERGENCY']+df2['NUMBER_INPATIENT']
[67]:	<pre># Dropping 'number_outpatient', 'number_emergency', 'number_inpatient' df2 = df2.drop(columns=['NUMBER_OUTPATIENT', 'NUMBER_EMERGENCY', 'NUMBER_INPATIENT'])  2. Nombre de changements de médicaments  df2['number_changes'] = np.nan for i in range(len(df2)):     n = 0</pre>
[69]: :[69]:	<pre>for j in meds:     if df2.loc[i, j] == -1 or df2.loc[i, j] == 1:         n += 1     df2.loc[i, 'number_changes'] = n  df2['number_changes'].value_counts()  0.0    16388     1.0    8417     2.0    485     3.0    44     4.0    3 Name: number_changes, dtype: int64</pre>
[70]:	<pre>Manie. Number_changes, dtype. Intoq  3. Nombre de médicaments diabétiques  df2['number_diab_meds'] = np.nan for i in range(len(df2)):     n = 0     for j in meds:         if df2.loc[i, j] != -2:             n += 1         df2.loc[i, 'number_diab_meds'] = n  df2.number_diab_meds=df2.number_diab_meds.astype('int64') df2['number_diab_meds'].value_counts()</pre>
[71]:	<pre>1    11618 2    6017 0    4547 3    2597 4    535 5    22 6     1 Name: number_diab_meds, dtype: int64  4. Insulin_treatment  df2['insulin_treatment'] = np.nan</pre>
[72]:	<pre>for i in range(len(df2)):     if df2.loc[i, 'INSULIN'] != -2 and df2.loc[i, 'number_diab_meds'] == 1:         df2.loc[i, 'insulin_treatment'] = 'insulin_only'     elif df2.loc[i, 'INSULIN'] != -2 and df2.loc[i, 'number_diab_meds'] &gt; 1:         df2.loc[i, 'insulin_treatment'] = 'insulin_combo'     elif df2.loc[i, 'INSULIN'] == -2 and df2.loc[i, 'number_diab_meds'] == 0:         df2.loc[i, 'insulin_treatment'] = 'no_med'     else:         df2.loc[i, 'insulin_treatment'] = 'other_meds' df2['insulin_treatment'].value_counts()</pre>
	<pre>insulin_only 8128 insulin_combo 7511 other_meds 5151 no_med 4547 Name: insulin_treatment, dtype: int64 number_diab_meds a été créé pour faire le traitement de l'insuline de la colonne, par conséquent nous le déposons  df2=df2.drop('number_diab_meds',1)     df2.reset_index(drop = True, inplace = True)</pre>
[74]: [75]:	<pre>Tests statistiques # Caractéristiques numériques num_cols = ['AGE_INT', 'TIME_IN_HOSPITAL', 'NUM_LAB_PROCEDURES', 'NUM_PROCEDURES', 'NUM_MEDICATIONS',</pre>
[76]: :[76]:	'TOLBUTAMIDE', 'INSULIN', 'GLYBURIDE_METFORMIN', 'GLIPIZIDE_METFORMIN', 'GLIMEPIRIDE_PIOGLITAZONE', 'METFORMIN_ROSIGLITAZONE', 'METFORMIN_PIOGLITAZONE', 'CHANGE', 'DIABETESMED', 'insulin_treatment']  df2.shape  (25337, 43)  len(num_cols)+len(cat_cols)
	Chi-2 pour les catégoriques vs catégoriques et one way anova pour les catégoriques vs numériques  Pour voir si les fonctionnalités sont significatives par rapport à la variable cible (readmitted)  #Statistical Tests (Chi Square and Anova)
	<pre>p_val = [] sig = [] for i in df2.columns:     if i in num_cols:         stat, p = stats.f_oneway(df2[df2['READMITTED'] == 0][i], df2[df2['READMITTED'] == 1][i])     else:         ct = pd.crosstab(df2[i], df2['READMITTED'])         stat, p, dof, exp = stats.chi2_contingency(ct)     p_val.append(p)     if p &lt; 0.05:         sig.append('Significant')     else:</pre>
z[78] <b>:</b>	<pre>sig.append("Insignificant") stats_df = pd.DataFrame({"columns" : df2.columns, "p_value" : p_val, "significance" : sig}) stats_df.sort_values(by='p_value', ascending = True)  columns</pre>
	32 INSULIN 2.382848e-22 Significant  14 NUMBER_DIAGNOSES 4.713655e-22 Significant  42 insulin_treatment 2.864962e-19 Significant  7 MEDICAL_SPECIALTY 3.399076e-17 Significant  41 number_changes 4.351799e-17 Significant  38 DIABETESMED 6.021855e-14 Significant  37 CHANGE 3.972180e-13 Significant
	11       DIAG_1       5.830308e-13       Significant         13       DIAG_3       5.561852e-11       Significant         6       TIME_IN_HOSPITAL       3.560013e-08       Significant         10       NUM_MEDICATIONS       3.950003e-06       Significant         12       DIAG_2       3.845994e-05       Significant         5       ADMISSION_SOURCE       1.367425e-03       Significant         17       METFORMIN       1.004162e-02       Significant         29       MIGLITOL       2.402984e-02       Significant
	16 A1CRESULT 2.851582e-02 Significant 26 PIOGLITAZONE 2.855366e-02 Significant 8 NUM_LAB_PROCEDURES 5.692811e-02 Insignificant 2 AGE_INT 6.031671e-02 Insignificant 18 REPAGLINIDE 8.278125e-02 Insignificant 24 GLYBURIDE 1.020866e-01 Insignificant 36 METFORMIN_PIOGLITAZONE 2.086789e-01 Insignificant 34 GLIPIZIDE_METFORMIN 2.086789e-01 Insignificant
	GLIPIZIDE 5.069747e-01 Insignificant  GLIMEPIRIDE 5.101057e-01 Insignificant  MAX_GLU_SERUM 5.208370e-01 Insignificant  ACARBOSE 5.234767e-01 Insignificant  NATEGLINIDE 5.251138e-01 Insignificant  NUM_PROCEDURES 5.700998e-01 Insignificant  ADMISSION_TYPE 6.691503e-01 Insignificant
	20 CHLORPROPAMIDE 7.680758e-01 Insignificant 31 TOLAZAMIDE 8.417851e-01 Insignificant 1 GENDER 8.508377e-01 Insignificant 0 RACE 8.786289e-01 Insignificant 27 ROSIGLITAZONE 8.986886e-01 Insignificant 33 GLYBURIDE_METFORMIN 9.191034e-01 Insignificant 25 TOLBUTAMIDE 1.000000e+00 Insignificant
[79]:	TROGLITAZONE 1.000000e+00 Insignificant  22 ACETOHEXAMIDE 1.000000e+00 Insignificant  35 GLIMEPIRIDE_PIOGLITAZONE 1.000000e+00 Insignificant  sig_cols = stats_df[stats_df['significance'] == 'Significant']['columns'].reset_index(drop = True) insig_cols = stats_df[stats_df['significance'] == 'Insignificant']['columns'].reset_index(drop = True) print('Statiscally significant features are :','\n') print(sig_cols)  Statiscally significant features are :
	0 DISCHARGE_DISPOSITION 1 ADMISSION_SOURCE 2 TIME_IN_HOSPITAL 3 MEDICAL_SPECIALTY 4 NUM_MEDICATIONS 5 DIAG_1 6 DIAG_2 7 DIAG_3 8 NUMBER_DIAGNOSES 9 A1CRESULT 10 METFORMIN 11 PIOGLITAZONE 12 MIGLITOL
[80]:	INSULIN CHANGE DIABETESMED READMITTED receding_year_visits number_changes insulin_treatment Name: columns, dtype: object  Mous pouvons supprimer toutes ces variables  df2 = df2.drop(['NATEGLINIDE','CHLORPROPAMIDE', 'ACETOHEXAMIDE', 'TOLBUTAMIDE', 'T
	'GLYBURIDE_METFORMIN', 'GLIPIZIDE_METFORMIN',
[83]: :[83]:	Emergency 17387 Elective 7913
	Not Available 37 Name: ADMISSION_TYPE, dtype: int64  df2['ADMISSION_SOURCE'].value_counts()  Emergency 13287 Referral 9637 Transferred from another health care facility 2413 Name: ADMISSION_SOURCE, dtype: int64
[84]: [85]: [85]:	Name: ADMISSION_TYPE, dtype: int64  df2['ADMISSION_SOURCE'].value_counts()  Emergency 13287 Referral 9637 Transferred from another health care facility 2413
[84]: [85]: [85]: [86]:	Name: ADMISSION_TYPE, dtype: int64  df2['ADMISSION_SOURCE'].value_counts()  Emergency
[84]: [85]: [85]: [86]:	Name: ADMISSION_TYPE, dtype: int64  df2['ADMISSION_SOURCE'].value_counts()  Emergency
[84]: [85]: [85]: [86]:	Name: ADMISSION_TYPE, dtype: lnt64  df2['ADMISSION_SOURCE'].value_counts()  Emergency Referral 9837 Transferred from another health care facility 2413 Name: ADMISSION_SOURCE, dtype: int64  ADMISSION_SOURCE et ADMISSION_TYPE sont similaires car les détails de ADMISSION_TYPE sont présents dans l'identifiant de la source d'admission. Nous pouvons donc supprimer ADMISSION_TYPE et simplement conserver ADMISSION_SOURCE  df2 = df2.drop(['ADMISSION_TYPE'], axis=1)  df2.shape  (25337, 29)  df2.columns  Index(['RACE', 'GENDER', 'AGE_INT', 'DISCHARGE_DISPOSITION', 'NAMISSION_SOURCE', 'TIME_IM_JOSPITAL', 'NRDICAL_SPECIALTY', 'NUM_LAB_PROCEDURES', 'NUM_PROCEDURES', 'NUM_PROCEDURES', 'NUM_PROCEDURES', 'NUM_PROCEDURES', 'NUM_PROCEDURES', 'NAME_GUS_SREMIM', 'AJGRESOUT', 'METTONNIN', 'REPAGLINIBE', 'GLIMPIRIDE', 'GLIPIZIDE', 'GLYDUAIDE', 'GLYDUAIDE', 'PIOGLITAZAONS', 'INSULIN', 'JOIATEMEMBED', 'READMITTED', 'drypocating year_visits', 'number_changes', 'insulin_treatment'],  Multi-Collinearity  plt.fiqure(fiquize=(8,5)) corr=df2[num_cole).corr() sna.heatnag(corr, annot-True, cmap="YIShBu') b,t=plt.ylim() plt.ylim() plt.yli
[84]: [85]: [86]: [87]:	### 1.00   1.00
[84]: [85]: [86]: [87]:	### AMMISSION_PYPER, dtype: smif4  ### dty 'AMMISSION_DOUGCE').velue_counts()  ### referral  ### ref
[84]: [85]: [86]: [87]:	### ### ##############################
[84]: [85]: [86]: [87]:	
[84]: [85]: [86]: [87]:	### STATE OF CONTROL O
[84]: [85]: [86]: [87]: [88]:	March
[84]: [85]: [86]: [87]: [88]:	### ADMINISTRATION OF THE PROPERTY OF THE PROP
[84]: [85]: [86]: [87]: [88]:	Company   Comp
[84]: [85]: [86]: [87]: [88]:	### Committee Co
[84]: [85]: [86]: [87]: [88]:	The control of the co
[84]: [85]: [86]: [87]: [88]: [90]:	### Company   Co
[84]: [85]: [87]: [88]: [90]: [91]:	Experience of the control of the con
[84]: [85]: [87]: [92]: [92]: [92]:	The second content of the content of
[84]: [85]: [87]: [92]: [92]: [92]:	The content of the co
[84]: [85]: [87]: [92]: [92]: [92]:	The content of the co
[84]: [85]: [87]: [92]: [92]: [92]:	The content of the co
[84]: [85]: [87]: [97]: [97]: [97]:	The content of the co
[84]: [85]: [87]: [92]: [92]: [92]:	The content of the co
[84]: [85]: [86]: [87]: [90]: [90]:	### Common Commo